



人工智能实践

Artificial Intelligence Practice

DCS3015 Autumn 2022

Chao Yu (余超)

School of Computer Science and Engineering
Sun Yat-Sen University



Lecture 3: 因果推断 (Causal Inference)

因果推断有什么用？

推断某些政策、干预带来的效应，帮助人们进行决策。

一些例子：

- 研究治疗方案对疾病的治疗效果
- 研究环保政策对气候的影响
- 研究社交媒体对心理健康的影响
- ...

为什么要学习因果推断？——从辛普森悖论开始说起

假定现在存在一种疾病，

现有两种治疗方案 (T) : A (0) , B (1)

存在两种病情 (C) : 轻微 (0) , 严重 (1)

治疗结果 (Y) : 存活 (0) , 死亡 (1)


经过治疗后，得到以下的死亡率数据：

	轻微	严重	总体
方案A	15% (210/1400)	30% (30/100)	16% (240/1500)
方案B	10% (5/50)	20% (100/500)	19% (105/550)

仅看整体数据，治疗方案A死亡率更低，我们应该继续使用方案A。可是如果我们从两种病情分别去看，似乎方案B更加有效？
也就是说如果我们知道病人的病情，我们应该使用方案B，如果不知道则使用方案A。显然，我们得出了一个相悖的结论！

是什么影响了我们的推断？——混淆变量（Confounder）

	轻微	严重	总体
方案 A	15% (210/1400)	30% (30/100)	16% (240/1500)
方案 B	10% (5/50)	20% (100/500)	19% (105/550)



因果图（Causal Graph）

一种可能的因果关系是病情（C）同时影响治疗方案（T）和治疗结果（Y）：

- 病情轻微：倾向使用方案A且死亡率低
- 病情严重：倾向使用方案B且死亡率高



我们称这里的病情为**混淆变量**。为了测量治疗方案的真实效果，必须排除混淆变量的干扰。

辛普森悖论

为什么在不同病情中方案B都更优，整体却是方案A更优？

$$\begin{aligned}
 P(Y = 1|T = 0) &= \sum_{c=0,1} P(Y = 1, C = c|T = 0) \\
 &= P(Y = 1|C = 0, T = 0)P(C = 0|T = 0) \\
 &\quad + P(Y = 1|C = 1, T = 0)P(C = 1|T = 0) \\
 &= 0.15 * \frac{1400}{1500} + 0.3 * \frac{100}{1500} = 0.16
 \end{aligned}$$

$$\begin{aligned}
 P(Y = 1|T = 1) &= \sum_{c=0,1} P(Y = 1, C = c|T = 1) \\
 &= P(Y = 1|C = 0, T = 1)P(C = 0|T = 1) \\
 &\quad + P(Y = 1|C = 1, T = 1)P(C = 1|T = 1) \\
 &= 0.1 * \frac{50}{550} + 0.2 * \frac{105}{550} = 0.19
 \end{aligned}$$



因果图 (Causal Graph)

	轻微	严重	总体
方案 A	15% (210/1400)	30% (30/100)	16% (240/1500)
方案 B	10% (5/50)	20% (100/500)	19% (105/550)

可以看到这里的加权系数对方案B来说是不公平的，为什么会产生这样的加权系数？

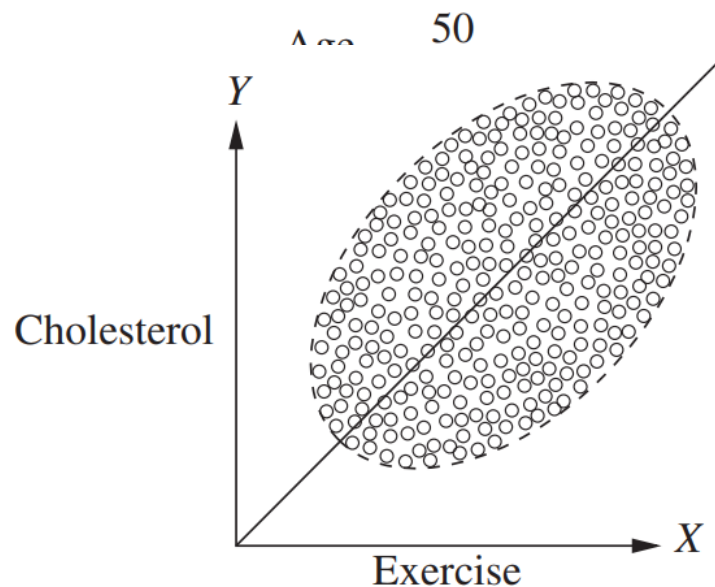
辛普森悖论

辛普森悖论——另一个案例

现有一份不同年龄段人群的锻炼量与胆固醇含量关系的统计数据

在不同的年龄段中，我们都可以看到锻炼量与胆固醇含量之间明显的负相关关系。

可当我们取消年龄这个维度再来看数据，却得到了锻炼量与胆固醇含量之间的正相关关系。进而导致我们得到错误的推论：锻炼的越多，胆固醇含量越高。




观察以下案例，思考是否需要分类数据来进行决策。

假定现对于肾结石存在两种治疗方案：方案A和方案B。而医生倾向于对较大结石（病情更为严重）使用治疗方案A，对小结石使用方案B。那么如果一个病人尚不知道自己的结石大小，他应该观察整体的治疗数据还是按结石大小分类后的治疗数据呢？（治疗数据即不同方案的治愈率数据）

相关性 with 因果性

相关性并不意味着因果性

下图数据显示每年游泳溺水人数与尼古拉斯·凯奇每年出演的电影数目呈现出高度的统计相关性^[1]。所以这意味着尼古拉斯·凯奇观察到溺水人数增多，遂有意参演更多电影来宣扬相关安全问题？又或者是他有兴趣增加他在因果推断从业者中的知名度，所以刻意人为的制造了这些数据？显然这些推断是荒谬的，以上两个数据之间的统计相关性是偶然的，因此也不具备因果关系。



相关性与因果性


相关性并不意味着因果性

假设你现有一笔研究穿鞋睡觉与醒来头疼之间关系的数据。数据显示绝大多数时候人们穿鞋睡觉都会在醒来时头疼；而人们不穿鞋睡觉时，则一般不在醒来时觉得头疼。

人们在遇到这样的数据时，通常会将二者联系起来并得出以下的结论：穿鞋睡觉会导致醒来时头疼。一些小编甚至进而据此结论编写这样的文章：

“长期穿鞋睡觉会增大阿尔兹海默症患病概率！”

而事实上我们知道，这两者都可能受一个共同原因影响：睡前大量饮酒。因此我们观察到的相关性实际由两部分组成：1) 饮酒带来的相关关系；2) 穿鞋睡觉与醒来头疼之间的因果关系。而第二部分才是我们在寻找的因果关系。



结构化因果模型

结构化因果模型

为了进一步研究因果性，我们引入结构化因果模型（Structural Causal Models, SCM）来形式化描述不同元素之间的相关关系，进而研究他们是如何相互影响的。

一个SCM包括两个变量集合， U 和 V ，以及一个函数集合 F 。

- U : U 中的变量称为外生变量（exogenous variables），我们引入这些变量，但我们不考虑这些变量如何被其它变量影响。
- V : V 中的变量称为内生变量（endogenous variables），我们想知道它们与其他变量之间的因果关系。
- F : 集合 F 中的元素是一系列函数，这些函数根据其他变量来决定集合 V 中变量的取值。

每个SCM都存在一个对应的图， U 、 V 中的变量对应图中的节点， F 中的函数即对应图中的边。如果以图论语言描述，那么外生变量与内生变量存在以下关系：每一个内生变量是至少一个外生变量的后代；外生变量不能是模型中其它变量的后代，即外生变量为图中的根节点。


结构化因果模型

结构化因果模型——示例一：薪酬水平

$$U = \{X, Y\}, V = \{Z\}, F = \{f_Z\}$$
$$f_Z: Z = 2X + 3Y$$

以上SCM模型表示薪酬（Z）与受教育年限（X）以及工作年限（Y）之间的关系。由于X和Y同时出现在了函数 f_Z 中，因此称X和Y是Z的直接原因

（direct cause）。如果X和Y还存在祖先，那么称这些祖先是Z的潜在原因（potential cause）。该SCM对应的图如下所示，通过该图可以更直观的看出变量之间的因果关系。



结构化因果模型

结构化因果模型——示例二：篮球表现


$U = \{U_1, U_2, U_3\}, V = \{Height, Sex, Performance\}, F = \{f_1, f_2\}$

$Sex = U_1,$

$Height = f_1(Sex, U_2),$


$Performance = f_2(Height, Sex, U_3)$

这里的 $U = \{U_1, U_2, U_3\}$ 为我们并不关心如何命名且也不易测量的外生变量，但是它们会影响我们关心的 V 中的内生变量。尝试画出该SCM对应的图模型？



结构化因果模型

Intransitive Case



X 是 Y 的直接原因， Y 是 Z 的直接原因，但 X 可能与 Z 独立。


$$U = \{U_X, U_Y, U_Z\}, V = \{X, Y, Z\}, F = \{f_X, f_Y, f_Z\}$$

$$f_X: X = U_X,$$

$$f_Y: Y = \begin{cases} a & \text{if } X = 1, U_Y = 1 \\ b & \text{if } X = 2, U_Y = 1 \\ c & \text{if } U_Y = 2 \end{cases}$$


$$f_Z: Z = \begin{cases} i & \text{if } Y = c \text{ or } U_Z = 1 \\ j & \text{if } U_Z = 1 \end{cases}$$

在这个例子中，改变 X 的取值只会使得 Y 取值 a 或 b ，而仅当 Y 取值为 c 时才会影响 Z 的取值，因此 X 和 Z 是独立的。



潜在结果 (Potential Outcome)

因果推断——推断动作或策略对某些结果的影响



潜在结果

潜在结果：notation

$do(T = 1)$



$Y_i|_{do(T=1)} \triangleq Y_i(1)$



T : 实施的动作

Y : 观察到的结果

i : 作为下标表示具体的个体

$Y_i(1)$: 实施动作的潜在结果

$Y_i(0)$: 不实施动作的潜在结果

$do(T = 0)$



$Y_i|_{do(T=0)} \triangleq Y_i(0)$




Causal effect

$Y_i(1) - Y_i(0)$

因果推断的基本问题

因果推断的基本问题

Counterfactual



T : 实施的动作


Y : 观察到的结果

i : 作为下标表示具体的个体

$Y_i(0)$: 实施动作的潜在结果

$Y_i(1)$: 不实施动作的潜在结果

Factual




Causal effect

$Y_i(1) - Y_i(0)$

因果推断的基本问题

因果推断的基本问题



T : 实施的动作


Y : 观察到的结果

i : 作为下标表示具体的个体

$Y_i(0)$: 实施动作的潜在结果

$Y_i(1)$: 不实施动作的潜在结果

Counterfactual



Causal effect

$Y_i(1) - Y_i(0)$

因果推断的基本问题

平均处理效应(Average Treatment Effect, ATE)

$$\mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] \not\equiv \mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]$$

i	T	Y	Y(1)	Y(0)	Y(1)-Y(0)
1	0	0	?	0	?
2	1	1	1	?	?
3	1	0	0	?	?
4	0	0	?	0	?
5	0	1	?	1	?
6	1	1	1	?	?

T : 实施的动作

Y : 观察到的结果

i : 作为下标表示具体的个体

$Y_i(0)$: 实施动作的潜在结果

$Y_i(1)$: 不实施动作的潜在结果

$$\frac{2}{3} \quad \frac{1}{3}$$



$$\frac{2}{3} - \frac{1}{3} = \frac{1}{3}$$

因果推断的基本问题

相关性并不意味着因果性

例如穿鞋睡觉和醒来头疼有着很强的相关性，但这源于它们有一个共同原因：睡前喝了大量的酒。

因此穿鞋睡觉的群体和不穿鞋睡觉的群体除了是否穿鞋不同以外，还受这样一个重要变量的影响。




因果推断的基本问题

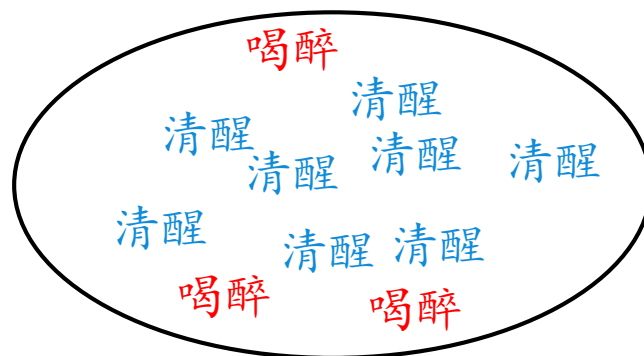
这两个群体不能直接比较，我们需要控制变量

$$\mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] \not\equiv \mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]$$

穿鞋睡觉的群体($T = 1$)



不穿鞋睡觉的群体($T = 0$)

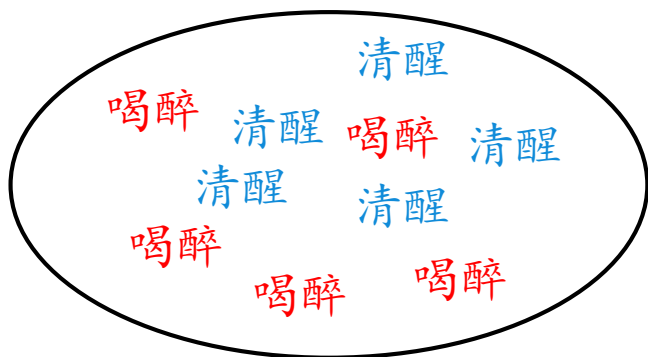


因果推断的基本问题


那么什么样的群体是可以比较的？

$$\mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] = \mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]$$

穿鞋睡觉的群体($T = 1$)



不穿鞋睡觉的群体($T = 0$)






因果推断的基本问题

什么条件下我们可以认为相关性等于因果性？



因果推断的基本问题

Ignorability: $(Y(1), Y(0)) \perp\!\!\!\perp T$

$$\begin{aligned}\mathbb{E}[Y(1) - Y(0)] &= \mathbb{E}[Y(1)|T] - \mathbb{E}[Y(0)|T] \\ &= \mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]\end{aligned}$$





另一种角度：exchangeability



因果推断的基本问题

另一种角度：exchangeability



交换前

交换后

$$\mathbb{E}[Y(1)|T = 1] = \mathbb{E}[Y(1)|T = 0] = \mathbb{E}[Y(1)]$$

$$\mathbb{E}[Y(0)|T = 0] = \mathbb{E}[Y(0)|T = 1] = \mathbb{E}[Y(0)]$$



因果推断的基本问题

Identifiability

$$\mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] = \mathbb{E}[Y(1)|T = 1] - \mathbb{E}[Y(0)|T = 0] (\text{ignorability})$$

$$\text{因果性度量} = \mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]$$


相关性度量

(如果我们知道 $P(x, t, y)$, 那我们可以计算得到该项数据)

如果一个因果性度量(如 $\mathbb{E}[Y(1)]$)可以利用某些统计数据(如 $\mathbb{E}[Y|t]$)计算得出, 那么称该因果性度量是可识别的 (identifiability)。

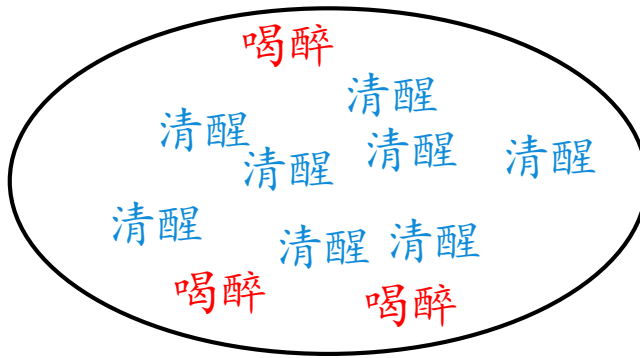

因果推断的基本问题

随机对照试验(Randomized control trial, RCT)



穿鞋睡觉的群体($T = 1$)


不穿鞋睡觉的群体($T = 0$)



随机对照试验的基本方法是，将研究对象**随机分组**，对不同组实施不同的干预，在这种严格的条件下对照效果的不同。在研究对象数量足够的情况下，这种方法可以抵消已知和未知的**混杂因素**对各组的影响。

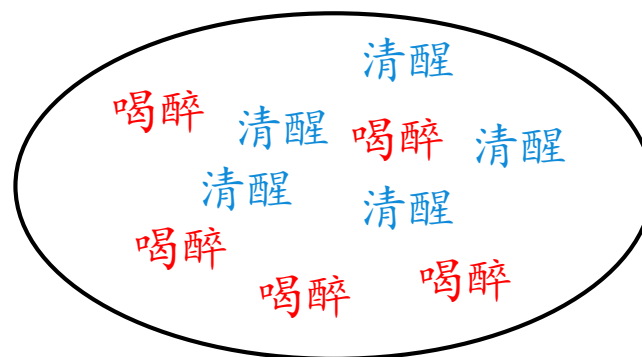
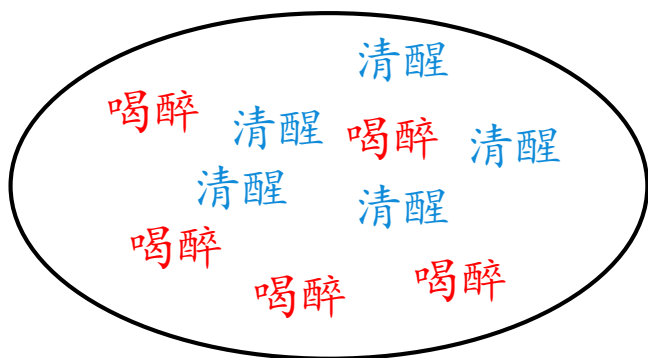
因果推断的基本问题

随机对照试验(Randomized control trial, RCT)



穿鞋睡觉的群体($T = 1$)




不穿鞋睡觉的群体($T = 0$)



随机对照试验的基本方法是，将研究对象**随机分组**，对不同组实施不同的**干预**，在这种严格的条件下对照效果的不同。在研究对象数量足够的情况下，这种方法可以抵消已知和未知的**混杂因素**对各组的影响。

因果推断的基本问题

RCT的图形化阐释



因果推断的基本问题

但并不总是能使用对照试验


- 道德原因：比如不能随机让人们抽烟来检验其对肺癌的影响
- 方案不可行：比如不能随机让不同国家实施共产主义/资本主义制度来测量制度对GDP的影响
- 完全不可能：比如不能改变一个人的DNA来测量其对身高的影响

因果推断的基本问题

Conditional exchangeability


Exchangeability

$$(Y(1), Y(0)) \perp\!\!\!\perp T$$



Conditional exchangeability:

$$(Y(1), Y(0)) \perp\!\!\!\perp T | X$$





因果推断的基本问题

识别条件平均处理效应(Identification of conditional average treatment effect)

$$\begin{aligned}\mathbb{E}[Y(1) - Y(0)|X] &= \mathbb{E}[Y(1)|X] - \mathbb{E}[Y(0)|X] \\ &= \mathbb{E}[Y(1)|T = 1, X] - \mathbb{E}[Y(0)|T = 0, X] \\ &= \mathbb{E}[Y|T = 1, X] - \mathbb{E}[Y|T = 0, X]\end{aligned}$$

但我们想要知道的是 $\mathbb{E}[Y(1) - Y(0)]$ ，怎么计算？



因果推断的基本问题

调整公式(The Adjustment Formula)

$$\begin{aligned}\mathbb{E}[Y(1) - Y(0)] &= \mathbb{E}_X \mathbb{E}[Y(1) - Y(0) | X] \\ &= \mathbb{E}_X [\mathbb{E}[Y | T = 1, X] - \mathbb{E}[Y | T = 0, X]]\end{aligned}$$


因果推断的基本问题

Unconfoundedness假设往往不易验证

unconfoundedness = conditional ignorability = conditional exchangeability

Conditional exchangeability:

$$(Y(1), Y(0)) \perp\!\!\!\perp T | X$$



因果推断的基本问题


Unconfoundedness假设往往不易验证

unconfoundedness = conditional ignorability = conditional exchangeability

Conditional exchangeability:

$(Y(1), Y(0)) \perp\!\!\!\perp T | X$

但如果存在不知道的混淆变量以上假设就不再成立了



因果推断的基本问题

Positivity

对于所有需要控制的协变量 x , 满足以下条件:

$$0 < P(T = 1|X = x) < 1$$


回忆调整公式:

$$\begin{aligned} \mathbb{E}[Y(1) - Y(0)] &= \mathbb{E}_X \mathbb{E}[Y(1) - Y(0)|X] \\ &= \mathbb{E}_X [\mathbb{E}[Y|T = 1, X] - \mathbb{E}[Y|T = 0, X]] \end{aligned}$$

$$\begin{aligned} &\sum_x \left(\sum_y y P(Y = y|T = 1, X = x) - \sum_y y P(Y = y|T = 0, X = x) \right) \\ &\sum_x \left(\sum_y y \frac{P(Y = y|T = 1, X = x)}{\underline{P(T = 1|X = x)P(X = x)}} - \sum_y y \frac{P(Y = y|T = 0, X = x)}{\underline{P(T = 0|X = x)P(X = x)}} \right) \end{aligned}$$


因果推断的基本问题

另一种角度：重叠



因果推断的基本问题

另一种角度：重叠



因果推断的基本问题

Positivity与Unconfoundedness之间的权衡


50%重叠

一维情况：



25%重叠

二维情况：




因果推断的基本问题

外推(Extrapolation)

$$\sum_x \mathbb{E}[Y|T=1, X] - \mathbb{E}[Y|T=0, X]$$

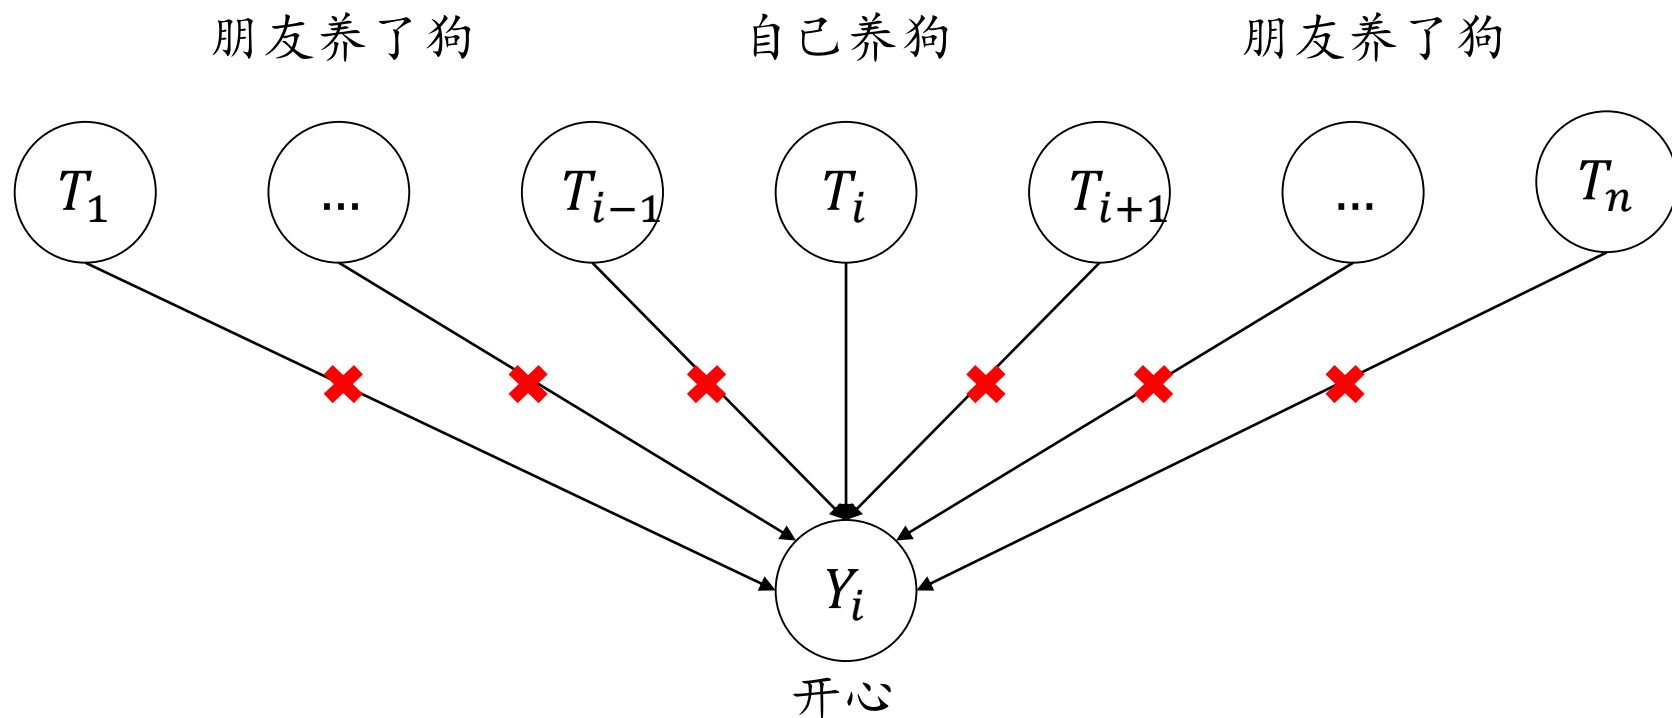
使用 $f_1(x)$ 拟合 使用 $f_0(x)$ 拟合



因果推断的基本问题

无干扰(No interference)

$$Y_i(t_1, \dots, t_{i-1}, t_i, t_{i+1}, \dots, t_n) = Y_i(t_i)$$



因果推断的基本问题

一致性(Consistency): $T = t \Rightarrow Y = Y(t)$

$$T = 1$$

拥有小狗

$$T = 0$$

没有小狗



一只聪明狗

$$T = 1 \Rightarrow Y = 1 \text{ 开心}$$



一只傻狗

$$T = 1 \Rightarrow Y = 0 \text{ 不开心}$$

违背了一致性假设

因果推断的基本问题


尝试回答以下问题：

1. 要估计平均处理效应，需要满足的四个假设是什么？
2. 为什么违背Positivity假设时需要外推(Extrapolation)？
3. 什么是可识别性(Identifiability)？

因果推断的基本问题

复习一下：

No interference



$$\mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$$

linearity of expectation

$$= \mathbb{E}_X[\mathbb{E}[Y(1)|X] - \mathbb{E}[Y(0)|X]]$$

law of iterated expectations

$$= \mathbb{E}_X[\mathbb{E}[Y(1)|T = 1, X] - \mathbb{E}[Y(0)|T = 0, X]]$$

unconfoundedness and positivity

$$= \mathbb{E}_X[\mathbb{E}[Y|T = 1, X] - \mathbb{E}[Y|T = 0, X]]$$


consistency

估计因果效应

Estimands, Estimates, Identification-Estimation Flowchart

- Estimand: 我们想要估计的量
 - Causal estimand(如 $\mathbb{E}[Y(1) - Y(0)]$)
 - Statistical estimand(如 $\mathbb{E}_X[\mathbb{E}[Y|T = 1, X] - \mathbb{E}[Y|T = 0, X]]$)
- Estimate: 使用已有数据对Estimand进行估计得到的近似值
- Estimation: 利用数据进行估计的过程

The Identification-Estimation Flowchart



估计因果效应

问题：钠摄入量对血压的影响

研究动机：快节奏的生活使得如今越来越多的人患上了高血压，血管壁长期承受着高于正常的压力会导致冠心病、脑卒中等严重疾病。

数据：

- 案例取自于 [Luque-Fernandez et al. \(2018\)](#)
- Outcome Y: 血压（连续型变量）
- Treatment T: 钠摄入量（大于3.5mg为1，否则为0）
- Covariates X: 年龄以及尿液中蛋白质含量
- Simulation: 我们知道“真实”ATE是1.05

估计因果效应

Estimation of ATE

True ATE: $\mathbb{E}[Y(1) - Y(0)] = 1.05$

Identification: $\mathbb{E}[Y(1) - Y(0)] = \mathbb{E}_X[\mathbb{E}[Y|T = 1, X] - \mathbb{E}[Y|T = 0, X]]$

Estimation: $\frac{1}{n} \sum_x [\mathbb{E}[Y|T = 1, X] - \mathbb{E}[Y|T = 0, X]]$

线性回归模型

Estimate: 0.85

$$\frac{|0.85 - 1.05|}{1.05} \times 100\% = 19\%$$

Naive: $\mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]$

Estimate: 5.33

$$\frac{|5.33 - 1.05|}{1.05} \times 100\% = 407\%$$

估计因果效应

利用线性回归模型的系数

假设Y与T、X满足线性关系: $Y = \alpha T + \beta X$

使用线性回归模型进行拟合: $Y = \hat{\alpha}T + \hat{\beta}X$ $\hat{\alpha} = 0.85$

当T是离散型变量时: $E[Y(1) - Y(0)]$

当T是连续型变量时: $E[Y(t)] \longrightarrow \hat{\alpha} = 0.85$

限制: 如此估计得到的因果效应对每个个体来说都是一样的

$$\begin{aligned} Y_i(t) &= \alpha t + \beta x_i \\ Y_i(1) - Y_i(0) &= \alpha \cdot 1 + \beta x_i \\ &\quad - \alpha \cdot 0 + \beta x_i = \alpha \end{aligned}$$


参考 [Morgan & Winship \(2014\)](#) 的6.2与6.3节

贝叶斯网络与因果图

简单的对联合分布建模

概率模型（无因果关系）： $P(x_1, x_2, \dots, x_n) = P(x_1) \prod_i P(x_i | x_{i-1}, \dots, x_1)$

$$P(x_1, x_2, x_3, x_4) = P(x_1)P(x_2|x_1)P(x_3|x_2, x_1)P(x_4|x_3, x_2, x_1)$$



x_1	x_2	x_3	$P(x_4 \mid x_3, x_2, x_1)$
0	0	0	α_1
0	0	1	α_2
0	1	0	α_3
0	1	1	α_4
1	0	0	α_5
1	0	1	α_6
1	1	0	α_7
1	1	1	α_8


2^{n-1} 个参数！

贝叶斯网络与因果图

局部马尔可夫假设(Local Markov assumption)

当在有向无环图中给定了一个节点的所有父节点，那么这个节点就和除了其后代的所有其它节点独立。

$$\begin{aligned} P(x_1, x_2, x_3, x_4) &= P(x_1)P(x_2|x_1)P(x_3|x_2, x_1)P(x_4|x_3, x_2, x_1) \\ &= P(x_1)P(x_2|x_1)P(x_3|x_2, x_1)P(x_4|x_3) \end{aligned}$$




局部马尔可夫假设(Local Markov assumption)

当在有向无环图中给定了一个节点的所有父节点，那么这个节点就和除了其后代的所有其它节点独立。

$$\begin{aligned} P(x_1, x_2, x_3, x_4) &= P(x_1)P(x_2|x_1)P(x_3|x_2, x_1)P(x_4|x_3, x_2, x_1) \\ &= P(x_1)P(x_2|x_1)P(x_3|x_2, x_1)P(x_4|x_3) \end{aligned}$$


现在该如何分解？

$$P(x_1)P(x_2)P(x_3|x_1)P(x_4|x_3)$$




贝叶斯网络分解(Bayesian network factorization)

$$P(x_1, x_2, \dots, x_n) = \prod_i P(x_i | pa_i)$$



Minimality assumption


1. 当在有向无环图中给定了一个节点的所有父节点，那么这个节点就和除了其后代的所有其它节点独立（局部马尔可夫假设）。
2. 有向无环图中的相邻节点之间相互依赖。



局部马尔可夫假设只告诉了我们变量之间的独立性，仅依据上图和局部马尔可夫假设，我们既可以认为 $P(x, y) = P(x)P(y|x)$ ，也可以认为 $P(x, y) = P(x)P(y)$ 。因此需要引入第二点，保证图中的边对应了变量之间的依赖关系。

Minimality也就是说图中没有多余的无用边，保证有向无环图能够明确表示变量之间的关系。

假设之间的关联





贝叶斯网络与因果图

尝试回答以下问题：

1. 局部马尔可夫假设和贝叶斯网络分解是什么关系？
2. Minimality假设的两点分别是什么？第二点告诉了我们什么？



贝叶斯网络与因果图


什么是cause?

如果变量 X 的改变会引起变量 Y 变化, 那我们称变量 X 是变量 Y 的一个原因(cause)。

Causal edges assumption

在一个有向图中，每一个父节点都是其所有子节点的原因(cause)。

假设之间的关联




图的基本结构


图的基本组成结构




Chain



Fork





Immorality





图的基本结构

Chains与Forks




图的基本结构

Chains与Forks




图的基本结构

Chains与Forks




blocked path




blocked path

图的基本结构

Chains与Forks



unblocked path




unblocked path

图的基本结构

Chain中条件独立的证明

目标: $P(x_1, x_3 | x_2) = \boxed{P(x_1 | x_2)} \underline{P(x_3 | x_2)}$




1. 贝叶斯网络分解: $P(x_1, x_2, x_3) = P(x_1)P(x_2 | x_1)P(x_3 | x_2)$

2. 应用贝叶斯公式: $P(x_1, x_3 | x_2) = \boxed{\frac{P(x_1)P(x_2 | x_1)}{P(x_2)}} \underline{P(x_3 | x_2)}$

3. 再次应用贝叶斯公式:
$$P(x_1, x_3 | x_2) = \frac{P(x_1, x_2)P(x_3 | x_2)}{P(x_2)}$$
$$= P(x_1 | x_2)P(x_3 | x_2)$$

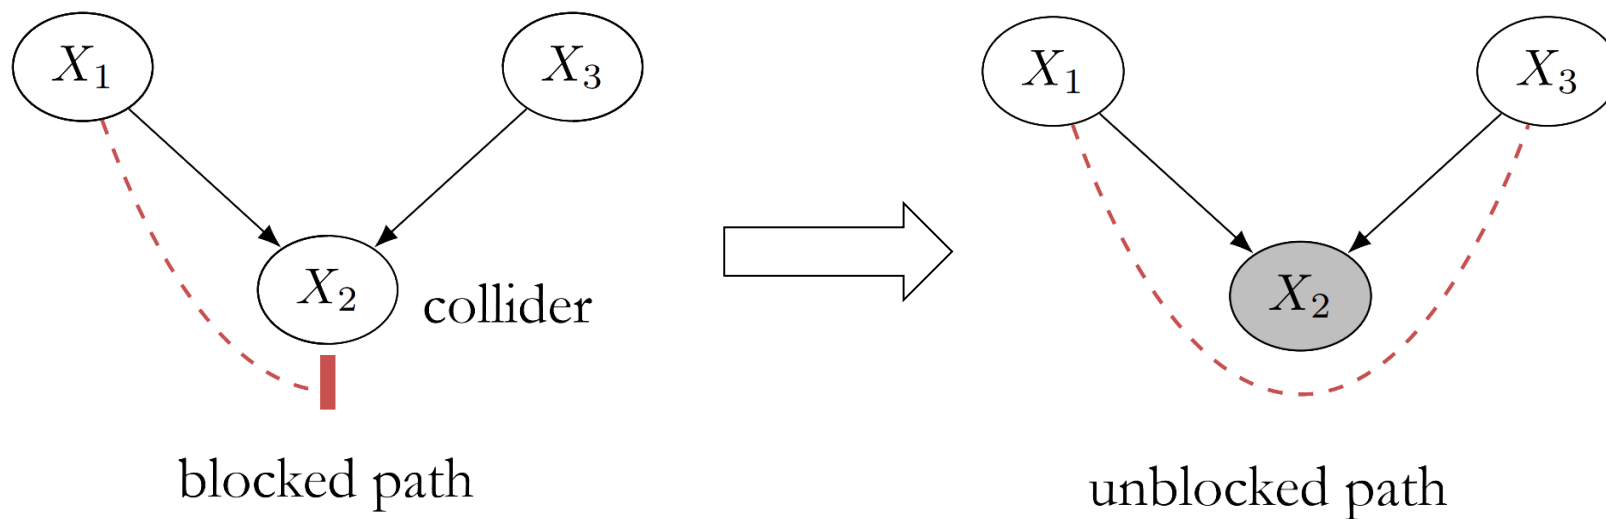
图的基本结构

Immoralities



$$\begin{aligned} P(x_1, x_3) &= \sum_{x_2} P(x_1, x_2, x_3) \\ &= \sum_{x_2} P(x_1)P(x_3)P(x_2|x_1, x_3) \\ &= P(x_1)P(x_3) \sum_{x_2} P(x_2|x_1, x_3) \\ &= P(x_1)P(x_3) \end{aligned}$$


Immoralities: conditioning on the collider



例如: $X_2 = X_1 + X_3$

Conditioning on descendants of colliders

$$X_1 \not\perp\!\!\!\perp X_3 \mid X_4$$



相关与因果关系的流动

阻塞路径(Blocked path)

对于节点X与节点Y之间的一条路径，如果下面条件中任意一条成立，则称X与Y被条件集Z阻塞：

1. 如果W在条件集Z中($W \in Z$)，且这条路径中存在chain ($\dots \rightarrow W \rightarrow \dots$) 或者 fork ($\dots \leftarrow W \rightarrow \dots$) 结构。
2. 路径中存在collider W，并且W及其后代都不在条件集Z中($W \notin Z, de(W) \notin Z$)。



相关与因果关系的流动

D分离(d-separation)

如果两个节点（集合） X 与 Y 之间的所有路径都被条件集 Z 阻塞，则称 X 与 Y 被 Z **D分离**。

D分离(d-separation)

